

TAREA COMPLEMENTARIA 5

$$\textcircled{1} X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 \\ 0 & 0 & 4 & 4 \\ 0 & 0 & 5 & 5 \\ 0 & 0 & 2 & 2 \end{bmatrix} \begin{array}{l} \rightarrow p1 \\ \rightarrow p2 \\ \\ \\ \rightarrow p6 \end{array}$$

$\downarrow \qquad \qquad \downarrow$
señal 1 señal 4

SVD $\rightarrow$ 2 componentes principales

- a) La aplicación de PCA/SVD significa que se busca representar los datos de forma más simple o más reducida, ya que la reducción de 4 señales a solo 2 componentes principales permite observar de mejor manera los patrones presentes en los datos.
- b) Se presenta redundancia porque los datos de la columna 1 son iguales a los de la 2, de igual forma, la columna 3 es igual a la 4. Entonces, no se necesitan las 4 columnas para describir la información del dataset, solo bastan dos componentes principales.

c) Sea

$$\sigma_1 = 7.35 \rightarrow \sigma_1^2 = 54.0225$$

$$\sigma_2 = 5.10 \rightarrow \sigma_2^2 = 26.01$$

$$\text{Su suma es } \sigma_1^2 + \sigma_2^2 = 80.325$$

% Su porcentaje de varianza es:

$$\bullet \text{ PC1} = \frac{54.0225}{80.325} \times 100 \approx 67.5\% //$$

$$\bullet \text{ PC2} = \frac{26.01}{80.325} \times 100 \approx 32.38\% //$$

d) Lucía = [3 3 0 0]

Lucía se representa mejor con el grupo de los pacientes 1-3 porque posee su mismo patrón: valores presentes en las dos primeras señales y valores nulos en las dos últimas. Además, tiene valores igual al paciente 2.

e) La estandarización antes de aplicar PCA/SVD es necesaria cuando las variables tienen diferentes escalas o unidades, ya que puede suceder que aquellas variables con mayor magnitud escalar dominen las componentes principales por su mayor variabilidad entre valores.

Entonces, en un caso biomédico no se harían evidentes los patrones clínicos relevantes, generando un resultado no confiable.

2)
$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$
 C_k , conjunto de puntos del clúster k
 μ_k , centroide del clúster k

a) Minimizar J significa reducir la distancia entre los puntos de un clúster y su centroide, acercarlos para encontrar una agrupación de puntos lo más parecidos entre sí.

b) El centroide representa un perfil promedio de todos los puntos dentro de un clúster. En el contexto biomédico se podría representar como un paciente típico de un grupo o una señal promedio.

c) La sensibilidad proviene de que los centroides son puntos iniciales de los que depende el resultado y no son fijos, ya que pueden ser aleatorios o definidos por alguna inicialización. Entonces diferentes inicializaciones pueden dar peores o mejores resultados.

d) No, porque depende de la inicialización de los centroides. Puede que se queden en un mínimo global o un mínimo local, es por ello que se ejecuta K-means varias veces para escoger el mejor resultado.

e) Como mencionado anteriormente, K-means necesita elegir el mejor resultado entre varias inicializaciones. Por ello, KMeans($n_{init}=10$) ayuda porque permite ejecutar 10 diferentes conjuntos de valores iniciales para los centroides, permitiendo quedarse con aquel con menor valor de J .

f) El dataset posee diferentes muestras tumorales con características propias. Estas son agrupadas por el PCA en componentes principales que contienen gran parte de la varianza resumida. Luego, con los pacientes representados con menos features, el K-means los agrupa en perfiles similares. Entonces, los centroides al ser el perfil promedio de cada grupo pueden ser interpretados como perfiles morfológicos.

g) • La sensibilidad del K-means a las escalas y datos atípicos o extremos puede perjudicar el resultado. En un problema biomédico es común ver ruido o pacientes atípicos que perjudiquen los valores promedio.

• Uno debe elegir y valorar cual es el mejor valor para el número de clústers (K). Sin embargo, en la vida real, uno no sabe realmente cuantos grupos hay frente a un conjunto desconocido.